

3차원 복부 CT 다장기 분할을 위한 계층적 조건부 확률 기반의 장기별 학습 상태 및 오류 유형 적응형 패치 샘플링

박용민 *

Hierarchical Conditional-Probability-Based Adaptive Patch Sampling with Organ-Wise Learning States and Error Types for 3D Abdominal CT Multi-Organ Segmentation

Yongmin Park*

요 약

3차원 복부 CT 상에서 수행하는 다장기 분할(multi-organ segmentation)에서는 패치 기반 학습(patch-based training)을 주로 사용하지만, 이러한 고정된 샘플링 방식은 장기별 학습 상태와 오류 유형을 반영하기 어렵다. 본 연구에서는 장기별 학습 상태와 오류 유형을 정량화하여 이를 계층적 조건부 확률로 모델링하는 적응형 패치 샘플링 방법을 제안한다. TotalSegmentator v2.0.1의 복부 장기 9개를 대상으로 실험한 결과, 제안 방법은 초기 학습 구간에서 기준 정책보다 높은 성능을 보였으나, 학습이 진행됨에 따라 정책 간 차이는 감소하였다.

Abstract

Patch-based training is commonly used for multi-organ segmentation in 3D abdominal CT, but fixed sampling strategies have difficulty reflecting organ-wise learning states and error types. In this study, we propose an adaptive patch sampling method that quantifies organ-wise learning states and error types and models them using a hierarchical conditional-probability structure. Experiments on nine abdominal organs from TotalSegmentator v2.0.1 showed that the proposed method achieved higher performance than the baseline during the early stage of training, while the performance gap between policies decreased as training progressed.

Key words

medical AI, computer vision, 3D image segmentation, abdominal CT, adaptive patch sampling

I. 서 론

이미지 분할(image segmentation)은 입력 영상의

관심 영역을 픽셀 또는 볼셀 단위로 구분하는 기법이다. 의료영상 분할(medical image segmentation)은 CT나 MRI에서 해부학적 구조를 자동으로 분할하는

*경기대학교 AI컴퓨터공학부, add28482848@kyonggi.ac.kr (교신저자)

※ "본 연구는 과학기술정보통신부 및 정보통신기획평가원의 SW중심대학지원사업의 연구결과로 수행되었음" (2021-0-01393)

데 사용되며, 특히 3차원 복부 CT 다장기 분할 (multi-organ segmentation)은 여러 해부학적 구조를 동시에 분할하여 장기 부피 측정 및 질환 분석 등에 활용된다[1].

반면 3차원 복부 CT는 많은 메모리와 계산량을 요구하여 전체 볼륨을 한 번에 학습하는 데 제약이 있다. 이에 따라 일부 영역을 패치 단위로 추출하는 패치 기반 학습(patch-based training)이 활용된다[2]. 그러나 샘플링 방식에 따라 학습 중 모델에 노출되는 영역이 달라질 수 있으며, 장기별 크기 차이에 따른 클래스 불균형과 학습 난이도 차이도 존재한다[3]. 3D 영상 분할의 대표적인 프레임워크인 nnU-Net은 무작위 패치 추출과 전경 과표집 (foreground oversampling)을 사용하지만, 이러한 고정적 샘플링 정책은 학습 과정에서 변화하는 장기별 학습 상태를 직접 반영하지 않는다[2].

이러한 한계를 보완하기 위해 예측 오류와 불확실성을 이용해 샘플링 분포를 동적으로 조정하는 적응형 패치 샘플링(adaptive patch sampling)이 제안되어 왔다[3]. 또한 다장기 분할에서는 어려운 패치를 우선 선택하는 온라인 하드 패치 마이닝 (online hard patch mining)도 제안되었다[4]. 그러나 이러한 접근은 장기 간 샘플링 우선순위와 장기 내부의 예측 오류 유형을 계층적으로 구분하여 모델링하지 않는다[3, 4]. 따라서 본 연구에서는 장기별 학습 상태와 오류 유형을 계층적 조건부 확률 구조로 모델링하는 적응형 패치 샘플링 방법을 제안한다.

II. 제안 방법

2.1 전체 수행 구조

본 연구의 제안 방법은 그림 1과 같이 학습 상태 추정, 계층적 조건부 선택, 패치 추출의 세 단계로 구성된다. 먼저 현재 모델의 예측 결과를 바탕으로 장기별 학습 상태를 계산하고 이를 장기 선택에 반영한다. 이후 선택된 장기 k 에 대해 오류 유형 r 과 후보 좌표 c 를 순차적으로 선택하고, 이때 선택된 후보를 중심 좌표로 설정하여 3D 패치를 샘플링한다.




그림 1. 제안하는 계층적 조건부 확률 기반 적응형 패치 샘플링의 전체 수행 구조

Fig. 1. Overall workflow of the proposed hierarchical conditional-probability-based adaptive patch sampling method.

2.2 장기별 학습 상태 추정 및 선택

본 연구에서는 현재 모델의 장기별 학습 상태를 정량적으로 추정하기 위해 각 장기의 Dice 점수 (Dice score)를 계산한다. 이때 $\widehat{Y}_k^{(t)}$ 와 Y_k 는 각각 모델의 예측 마스크(prediction mask)와 정답 마스크(ground-truth mask)를 의미하며, 갱신 시점 t 에서 장기 k 의 Dice 점수는 다음과 같다.

$$D_k^{(t)} = \frac{2|\widehat{Y}_k^{(t)} \cap Y_k|}{|\widehat{Y}_k^{(t)}| + |Y_k| + \epsilon} \quad (1)$$

여기서 ϵ 은 분모가 0이 되는 것을 방지하는 작은 양의 상수이다. $D_k^{(t)}$ 가 낮은 장기에 더 큰 값을 부여하기 위해 순간 장기 난이도(instantaneous organ difficulty) $e_t(k)$ 를 다음과 같이 정의한다.

$$e_t(k) = 1 - D_k^{(t)} \quad (2)$$

식 (2)의 $e_t(k)$ 는 갱신 시점에 따라 변동할 수 있으므로, 장기별 학습 상태를 안정적으로 추정하기 위해 다음과 같이 지수이동평균(exponential

moving average, EMA)을 적용한다.

$$d_t(k) = \beta d_{t-1}(k) + (1 - \beta) e_t(k) \quad (3)$$

여기서 $d_t(k)$ 는 갱신 시점 t 에서 장기 k 의 학습 상태를 나타내며, 값이 클수록 해당 장기의 학습이 다른 장기에 비해 부족함을 의미한다. β 는 이전 학습 상태 $d_{t-1}(k)$ 와 현재의 순간 장기 난이도 $e_t(k)$ 사이의 반영 비율을 조절하는 계수이다. 본 연구에서는 $\beta = 0.9$ 로 설정하였다. 이와 같이 추정된 $d_t(k)$ 를 기반으로 학습이 상대적으로 부족한 장기에 더 높은 선택 확률을 부여한다. 이때 특정 장기에 샘플링이 과도하게 집중되는 것을 방지하기 위해 다음과 같이 균등 선택 확률을 반영한다.

$$p_t(k) = \frac{1 - \lambda_k}{|K_t|} + \lambda_k \frac{d_t(k)}{\sum_{j \in K_t} d_t(j)} \quad (4)$$

이때 K_t 는 선택 가능한 장기의 집합이며, λ_k 는 균등 선택과 학습 상태 기반 선택 사이의 반영 비율을 조절하는 계수이다. 본 연구에서는 $\lambda_k = 0.5$ 로 설정하였다.

2.3 오류 유형 기반 조건부 선택

식 (4)에서 정의한 장기 선택 확률 $p_t(k)$ 에 따라 장기 k 를 선택한 뒤, 해당 장기에서 발생한 예측 오류를 세 가지 의미적 오류 유형으로 분해한다. 오류 유형 r 은 내부 누락(interior miss), 경계 불일치(boundary disagreement), 외부 오탐(exterior false positive)으로 구성되며, 각 오류 유형은 상호 배타적이다.

선택된 장기 k 에서 오류 유형별 후보 좌표의 구성 비율을 계산하기 위해, 각 오류 유형의 후보 좌표 수를 선택 가능한 오류 유형 전체의 후보 좌표 수로 정규화한다. 따라서 오류 유형 r 이 차지하는 상대적 비율을 다음과 같이 정의한다.

$$b_t(r|k) = \frac{|C_t(k, r)|}{\sum_{r' \in R_t(k)} |C_t(k, r')|} \quad (5)$$

여기서 $C_t(k, r)$ 는 갱신 시점 t 에서 장기 k 의 오류 유형 r 에 해당하는 후보 좌표 집합이며, $R_t(k)$ 는 후보 좌표가 존재하는 오류 유형의 집합이다. 현재 후보 분포 $b_t(r|k)$ 와 별도로, 관측된 오류 유형별 발생 비율에 지수이동평균을 적용하여 누적 오류 발생 경향을 추정하고, 이를 선택 가능한 오류 유형에 대해 정규화하여 $a_t(r|k)$ 로 정의한다. 이후 $b_t(r|k)$ 와 $a_t(r|k)$ 를 결합하여 오류 유형 r 의 조건부 선택 확률 $p_t(r|k)$ 을 다음과 같이 정의한다.

$$p_t(r|k) = (1 - \lambda_r) b_t(r|k) + \lambda_r a_t(r|k) \quad (6)$$

이때 λ_r 는 두 분포의 반영 비율을 조절하는 계수이며, 본 연구에서는 $\lambda_r = 0.5$ 로 설정하였다.

2.4 계층적 조건부 확률 기반 패치 샘플링

2.2와 2.3에서 각각 장기 k 와 오류 유형 r 이 선택되면, 후보 좌표 집합 $C_t(k, r)$ 에서 좌표 하나를 샘플링하여 패치의 중심으로 설정한다. 집합 내부의 각 후보 좌표에 대해서는 동일한 선택 확률을 부여하며, 좌표 c 에 대한 조건부 선택 확률 $p_t(c|k, r)$ 을 다음과 같이 정의한다.

$$p_t(c|k, r) = \frac{1}{|C_t(k, r)|} \quad (7)$$

따라서 앞서 정의한 세 단계의 선택 확률 $p_t(k)$, $p_t(r|k)$, $p_t(c|k, r)$ 를 결합하여 본 연구가 제안하는 전체 선택 확률 $p_t(k, r, c)$ 을 다음과 같이 모델링한다.

$$p_t(k, r, c) = p_t(k) p_t(r|k) p_t(c|k, r) \quad (8)$$

식 (8)에 따라 장기 k , 오류 유형 r , 후보 좌표 c 를 순차적으로 선택하고, 최종 선택 좌표를 중심으로 3D 패치를 추출한다. 제안 방법의 실제 적용 예시는 그림 2와 같다.




그림 2. 제안하는 계층적 적응형 패치 샘플링의 실제 복부 CT 데이터 적용 예시(case s0004).

(a) 장기 선택 및 오류 유형별 후보 좌표,

(b) 선택된 췌장(pancreas)의 3차원 오류 후보 분포, (c) 오류 유형별 조건부 선택 확률

Fig. 2. Example of the proposed hierarchical adaptive patch sampling applied to a real abdominal CT case (case s0004).

(a) Organ selection and candidate coordinates for each error type, (b) 3D distribution of error candidates for the selected pancreas, and (c) conditional selection probabilities for each error type.

III. 실험 및 결과

3.1 데이터셋 및 실험 설정

본 실험에서는 TotalSegmentator v2.0.1 데이터셋 [1]을 사용하였다. 전체 데이터셋 1,228개의 CT case 중, 본 연구에서 지정한 9개 장기 라벨을 모두 포함하는 602개 case를 선정하고, 이를 학습 525 case, 검증 28 case, 평가 49 case로 분할하였다. 분할 대상은 비장, 좌·우 신장, 담낭, 간, 위, 췌장 및 좌·우 부신의 총 9개 장기로 구성하였다. 세부 실험 환경 및 학습 설정은 표 1과 같다.

표 1. 실험 환경 및 학습 설정

Table 1. Experimental environment and training settings.

항목	설정
Dataset	TotalSegmentator v2.0.1
Data split	525 / 28 / 49 (train / val / test)
Target organs	9 abdominal organs
Framework	nnU-Net v2.8.1, 3d_fullres
Target spacing	$1.5 \times 1.5 \times 1.5$ mm
Patch size	$160 \times 112 \times 128$
Batch size	2
Training budget	30,000 updates
Reported checkpoints	10K, 20K, 30K
Evaluation metric	Case-first 9-organ macro Dice

이때 평가 지표는 각 case에서 9개 장기의 *Dice* 점수를 평균한 뒤, 이를 전체 case에 대해 평균하는 case-first 9-organ macro Dice를 사용하였다.

3.2 비교 방법

제안 방법의 구성 요소별 영향을 비교하기 위해 B0, B1, A1, P의 네 가지 샘플링 정책(sampling policy)을 각각 적용하였다. 위 정책은 모두 동일한 실험 조건에서 진행하였으며, 샘플링 정책만 다르게 설정하였다. 먼저 B0는 nnU-Net의 전경 과표집 방식을 그대로 사용하여 기준 정책(baseline)으로 설정하였다. 그리고 B1은 오류 후보 좌표를 사용하되, 장기 및 오류 유형에 대한 적응형 할당은 적용하지 않았다. A1은 B1에 장기별 학습 상태 $d_t(k)$ 를 반영한 장기 선택 확률 $p_t(k)$ 을 적용하였다. P는 A1에 오류 유형별 누적 오류 경향을 반영한 조건부 선택 확률 $p_t(r|k)$ 을 추가한 최종 제안 정책이다.

3.3 정량적 결과 및 분석

그림 3은 단일 discovery 실험(seed 55254)에서 B0, B1, A1, P의 네 가지 샘플링 정책에 따른 학습 단계별 case-first 9-organ macro Dice 변화를 나타낸다. 10K update에서 P는 0.7968의 Dice를 기록하

여 B0의 0.7455보다 5.12%p 높은 성능을 보였으며, B1과 A1보다도 높은 값을 나타냈다. 20K에서도 P는 0.9080으로 가장 높은 성능을 보였으며, B0와의 차이는 0.96%p로 감소하였다. 이후 30K에서는 B0, B1, A1, P가 모두 약 0.923 수준으로 수렴하여 정책 간 성능 차이가 거의 나타나지 않았다.




그림 3. 샘플링 정책별 학습 단계에 따른 case-first 9-organ macro Dice 변화

Fig. 3. Case-first 9-organ macro Dice across training stages for different sampling policies.

이러한 결과는 해당 실험에서 제안 정책이 학습 초기 구간의 패치 선택에 영향을 주어 상대적으로 높은 분할 성능을 보였으나, 학습이 진행될수록 그 차이가 감소했음을 보여준다. 특히 최종 학습 단계에서는 기본 전경 과표집을 사용한 B0와 제안 정책 P 사이의 성능 차이가 거의 없어, 제안 방법의 효과가 최종 성능보다는 초기 학습 과정에서 두드러지는 경향을 보였다. 추가 반복 실험에서 초기 성능 향상이 일관되게 나타나지는 않았으나, 일부 실험 결과는 제안 정책이 초기 학습 구간에서 성능 개선 가능성을 가짐을 시사한다.

IV. 결론

본 연구에서는 3차원 복부 CT 다장기 분할에서 학습 과정에 따라 변화하는 장기별 학습 상태와 장기 내부의 오류 유형을 함께 반영하기 위한 계층적 조건부 확률 기반 적응형 패치 샘플링 방법을 제안하였다. 제안 방법은 장기별 Dice 기반 학습 상태를 이용하여 장기 선택 확률을 조정하고, 선택된 장기 내부에서는 내부 누락, 경계 불일치, 외부 오탐의

오류 발생 경향을 반영하여 패치 후보를 선택한다. TotalSegmentator v2.0.1의 9개 복부 장기와 nnU-Net을 기반으로 네 가지 샘플링 정책을 비교한 결과, 일부 초기 학습 구간에서는 제안 정책의 성능 향상이 관찰되었으나 학습 후반에는 정책 간 성능 차이가 감소하였다. 또한 추가적인 반복 검증에서는 초기 성능 향상이 일관되게 재현되지 않아, 제안 방법의 안정적인 성능 우위를 확인하기에는 한계가 있었다. 따라서 본 연구는 장기와 오류 유형을 계층적으로 분리하여 패치 샘플링에 반영하는 구조를 제시했다는 데 의의가 있으며, 향후에는 보다 안정적인 학습 상태 추정과 오류 유형별 할당 방법을 통해 다양한 데이터셋과 학습 조건에서의 일반화 가능성을 검증할 필요가 있다.

참 고 문 헌

- [1] J. Wasserthal et al., "TotalSegmentator: Robust Segmentation of 104 Anatomic Structures in CT Images," *Radiology: Artificial Intelligence*, vol. 5, no. 5, e230024, 2023.
- [2] F. Isensee, P. F. Jaeger, S. A. A. Kohl, J. Petersen, and K. H. Maier-Hein, "nnU-Net: A Self-Configuring Method for Deep Learning-Based Biomedical Image Segmentation," *Nature Methods*, vol. 18, no. 2, pp. 203-211, 2021.
- [3] J. Park, A. Cho, and H.-J. Park, "Adaptive Patch Sampling and Location-Aware Reasoning for Whole Body PET-CT Multi-Organ Segmentation," *Scientific Reports*, vol. 16, Art. no. 22461, 2026.
- [4] J. He, G. Zhou, S. Zhou, and Y. Chen, "Online Hard Patch Mining Using Shape Models and Bandit Algorithm for Multi-Organ Segmentation," *IEEE Journal of Biomedical and Health Informatics*, vol. 26, no. 6, pp. 2648-2659, 2022.